

스터디 9주차 중간정리본(2~4주차 강의)

홍송은

1. 경사 하강법(Gradient Descent)

- 머신러닝 및 딥러닝에서 모델이 최적의 파라미터를 학습할 수 있도록 도와주는 대표적인 최적화 알고리즘
- 모델의 예측 결과와 실제 값 사이의 차이를 나타내는 비용 함수(Cost Function, Loss Function)의 값을 최소화하는 파라미터(가중치 등)를 찾기 위한 알고리즘
- 비용 함수가 가장 작은 지점(최솟값)을 향해 반복적으로 파라미터를 조정하며 찾아가는 역할

$$\theta^{(n+1)} = \theta^{(n)} - \alpha \nabla_{\theta} J(\theta^{(n)})$$

수식	의미
$\theta^{(n)}$	현재 n번째 반복에서의 파라미터 값
$\theta^{(n+1)}$	업데이트된 다음 파라미터 값
α	학습률(learning rate): 얼마나 크게 이동할지 결정하는 상수
$\nabla_{\theta} J(\theta^{(n)})$	비용 함수 J에 대한 현재 파라미터 위치에서의 기울기(Gradient)

작동 원리

- 기울기(gradients)
 - : 현재 파라미터 위치에서 비용 함수가 가장 빠르게 증가하는 방향
 - 반대 방향(-gradient)으로 이동하면 비용 함수가 작아진다!

기울기 $> 0 \rightarrow$ 오른쪽으로 갈수록 함수값이 증가 \rightarrow 왼쪽으로 이동 필요


기울기 $< 0 \rightarrow$ 왼쪽으로 갈수록 함수값이 증가 \rightarrow 오른쪽으로 이동 필요

- α 를 곱하는 이유
 - 이동 크기 조절
 - 너무 크면 발산하고, 너무 작으면 수렴이 느림

경사 하강법 단계

- ① 초기값 설정: 파라미터 θ 를 임의로 시작
- ② 기울기 계산: 현재 위치에서 비용 함수의 미분값 계산
- ③ 파라미터 업데이트: 위 수식을 따라 파라미터 값을 조정
- ④ 반복: 더 이상 개선이 없을 때까지 또는 정해진 횟수만큼 반복

예시)



장단점

- 장점
 - 간단하고 직관적이며 구현하기 쉬움
 - 선형회귀, 로지스틱회귀, 신경망 등 다양한 모델에 적용 가능
 - 단점
 - local minimum에 빠질 수 있음
 - 학습률에 따라 수렴에 영향을 줌

2. 예측함수 및 비용 함수

Hypothesis (가설 함수)

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

- 입력 x 가 주어졌을 때, 파라미터 θ_0, θ_1 을 기반의 예측값 $h_{\theta}(x)$ 생성 함수
- 단순 선형 회귀(Linear Regression) 형태

Cost Function (비용 함수)

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

수식	의미
m	전체 데이터 샘플 수
$x^{(i)}, y^{(i)}$	i번째 샘플의 입력과 실제 정답
$h_{\theta}(x^{(i)})$	i번째 입력에 대한 예측값
$(h_{\theta}(x^{(i)}) - y^{(i)})^2$	예측값과 실제값의 제곱 오차

- 제곱을 하는 이유?
 - 오차가 양수든 음수든 모두 양수로 반영되도록 하기 위함
 - 큰 오차에 대해 더 큰 패널티를 주기 위해 제곱을 사용
- $1/2m$ 의 의미?
 - 평균을 내기 위해 m 으로 나누고, 미분 시 계산이 간단해지도록 $1/2m$ 를 붙임
→ 미분하면 2가 사라짐

비용 함수 종류

- 회귀: Mean Squared Error(MSE)
→ 차이의 제곱을 합하여 평균을 계산

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

수식	의미
y_i	실제값
$\hat{y}_i = h_\theta(x_i)$	예측값
$(y_i - \hat{y}_i)^2$	예측값과 실제값의 차이의 제곱

- 이진 분류: Binary Cross Entropy
→ 분류 문제에서 모델이 출력한 확률이 실제 정답과 얼마나 가까운지 측정

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(h_\theta(x_i)) + (1 - y_i) \log(1 - h_\theta(x_i))]$$

수식	의미
m	전체 샘플 수
y_i	i번째 샘플의 실제 정답값 (0 또는 1)
$h_\theta(x_i)$	i번째 입력에 대한 예측 확률 (0~1)
$y_i \log(h_\theta(x_i))$	정답이 1일 때 작동 → 예측값이 1에 가까울수록 손실 작음
$(1 - y_i) \log(1 - h_\theta(x_i))$	정답이 0일 때 작동 → 예측값이 0에 가까울수록 손실 작음
$-\frac{1}{m}$	전체 샘플에 대해 평균 손실 계산

3. 선형 회귀 및 최소제곱법(OLS)

선형 회귀 (Linear Regression)

→ 입력 변수 x 와 출력 변수 y 사이의 선형 관계를 모델링하는 것

예시) 수입 $x \rightarrow$ 신용도 점수 y

- 가설 함수 (Hypothesis Function)

$$\hat{y}_i = \hat{\theta}_0 + \hat{\theta}_1 x_i$$

최소제곱법 (OLS: Ordinary Least Squares)

- 목표: 비용 함수 $J(\theta_0, \theta_1)$ 를 미분하여 최소값을 갖는 지점을 구하고, 이에 해당하는 $\hat{\theta}_0, \hat{\theta}_1$ 의 값을 도출

$$\widehat{\theta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\widehat{\theta}_0 = \bar{y} - \widehat{\theta}_1 \bar{x}$$