

## AI 개론+응용 정기평가 대비 예상 문제

홍승은

11 주차 스터디 컴퓨터비전 정기평가 대비 예상 문제 작성 및 풀이(개론) 중 문제 풀이 보완

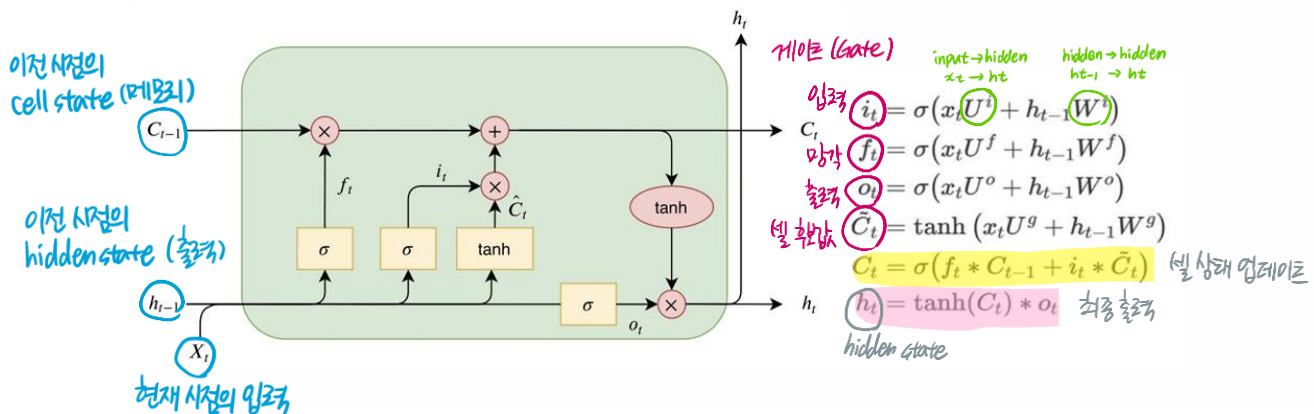
(전효재 - 문제 20 번)

다음은 LSTM 의 인스턴스를 만드는 코드이다. lstm 모델에서 학습해야 할 파라미터의 개수는 몇 개인지 구하시오.

```
input_dim = 7
hidden_size = 6
lstm = nn.LSTM(input_dim, hidden_size, batch_first=True)
```

(풀이) AI 개론 17 차시 강의자료 – LSTM 구조

### ▶ LSTM 구조



### 게이트 (Gate)

**input → hidden**  
 $x_t \rightarrow h_t$

**hidden → hidden**  
 $h_{t-1} \rightarrow h_t$

입력:  $i_t = \sigma(x_t U^i + h_{t-1} W^i)$

현재 시점의 입력  $x_t$ 가 hidden state 계산에 영향을 주는 weight  
 ∴ 입력  $x_t$ 에 곱해지는 weight matrix  
 shape =  $[4 \cdot \text{hidden}, \text{input-dim}]$

이전 시점의 hidden state  $h_{t-1}$ 가 현재 hidden state 계산에 영향을 주는 weight  
 ∴ 이전  $h_{t-1}$ 에 곱해지는 weight matrix  
 shape =  $[4 \cdot \text{hidden}, \text{hidden}]$

총 파라미터 수 =  $4 \times (\text{input\_dim} \times \text{hidden} + \text{hidden} \times \text{hidden} + 2 \times \text{hidden}) = 360$

1. 다음 중 실행 시 오류가 발생할 가능성이 있는 코드 조각을 모두 고르시오.

a.

```
nn.Conv2d(1, 32, kernel_size=5, padding='same')
```

b.

```
nn.Linear(784, 256)  
x = torch.randn(32, 784)  
x = x.view(784)
```

c.

```
x = torch.randn(1, 28, 28)  
x = x.unsqueeze(0)
```

d.

```
x = torch.randn(32, 3, 32, 32)  
model = nn.Conv2d(3, 16, kernel_size=3)  
y = model(x)
```

2. 아래 CNN의 출력 텐서 크기는?

```
nn.Conv2d(1, 8, kernel_size=3, stride=1, padding=0) # 입력: (1, 28, 28)
```

a. (8, 28, 28)

b. (8, 26, 26) # (C, H, W)

c. (1, 28, 28)

d. (8, 24, 24)

e. (1, 26, 26)

3. OpenCV 를 이용하여 엣지를 검출한 후, 윤곽선을 추출하고 중심 좌표를 반환하는 코드를 작성시오.

```
def get_object_center(img):
    gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
    edges = cv2.Canny(gray, 100, 200)
    contours, _ = cv2.findContours(edges, cv2.RETR_EXTERNAL,
                                   cv2.CHAIN_APPROX_SIMPLE)
    if len(contours) == 0:
        return None
    largest = max(contours, key=cv2.contourArea)
    M = cv2.moments(largest)
    cx = int(M["m10"] / M["m00"])
    cy = int(M["m01"] / M["m00"])
    return (cx, cy)
```

4. 다음 중 HSV 색공간의 장점으로 적절한 것을 모두 고르시오.
- a. H 는 색상, S 는 채도, V 는 명도를 의미한다.
  - b. HSV 는 조명 변화에 민감하다. → 덜 민감하다.
  - c. HSV 는 RGB 보다 사람의 색 인식 방식에 가깝게 표현한다.
  - d. OpenCV 에서 BGR → HSV 변환은 cv2.cvtColor 로 수행된다.
  - e. HSV 는 RGB 보다 빠른 연산을 지원한다. → 연산 속도가 느리다.
  - f. HSV 는 색상 기반 객체 추적에 자주 사용된다.

5. 다음 CamShift 를 사용한 추적 알고리즘 구현에서 빈칸을 채워 전체 로직을 완성하시오.

```
def camshift_tracking(frame, rc, hist):  
    hsv = cv2.cvtColor(frame, cv2.COLOR_BGR2HSV)  
    backproj = cv2.calcBackProject([hsv], [0], hist, [0, 180], 1)  
    term_crit = (cv2.TERM_CRITERIA_EPS | cv2.TERM_CRITERIA_COUNT, 10, 1)  
    ret, rc = cv2.CamShift(backproj, rc, term_crit)  
    cv2.ellipse(frame, ret, (0, 255, 0), 2)  
    return frame
```

6. 다음 중 영상 처리에서 기하학적 변환(Geometric Transformation)에 해당하지 않는 것은?
- a. 이미지 회전
  - b. 이미지 확대
  - c. 영상 이진화 → 픽셀 기반 연산
  - d. 전단(Shearing)
  - e. 아핀 변환
7. cv2.filter2D() 함수로 구현 가능한 필터링 기법을 모두 고르시오.
- a. 평균값 필터
  - b. 가우시안 블러 → cv2.GaussianBlur()
  - c. 샤프닝 필터
  - d. Sobel 필터
8. 다음 중 Lucas-Kanade Optical Flow 알고리즘의 특징으로 옳은 것들은?
- a. 모든 픽셀에 대해 흐름을 계산한다 → Dense Optical Flow
  - b. 특징점 기반 추적 방식이다
  - c. 작은 움직임 추적에 강하다
  - d. 연산량이 크고 느리다
  - e. 다중 해상도(Pyramid) 기반 개선이 가능하다

9. Depthwise Separable Convolution 의 장점으로 올바른 설명은?

- a. 채널 별 연산 분리를 통해 연산량 감소
- b. 3×3 필터만 사용 가능함
- c. 파라미터 수 감소
- d. Pointwise convolution 은 채널 간 정보를 통합
- e. 연산량은 일반 Conv 보다 약 8~9 배 적다
- f. 항상 정확도가 향상된다

10. 다음 중 Word2Vec 의 Skip-gram 방식 설명으로 올바른 것은?

- a. 전체 문서의 단어 분포를 벡터로 표현한다
- b. 주변 단어를 이용해 중심 단어를 예측한다
- c. 중심 단어로부터 주변 단어를 예측한다
- d. TF 와 IDF 를 곱하여 중요도를 반영한다
- e. 문장의 길이를 기준으로 벡터를 설정한다

11. TF-IDF 를 기반으로 텍스트 데이터를 벡터화하는 코드를 완성하시오.

```
from sklearn.feature_extraction.text import _____

text_data = ["나는 사과를 좋아해", "나는 바나나를 좋아해"]
vectorizer = TfidfVectorizer()
vectorizer.fit(text_data)
X = vectorizer.transform(text_data).toarray()
```

12. 다음 중 TF-IDF 에서 고려하는 정보로 올바른 항목을 모두 고르시오.

- a. 단어의 빈도
- b. 단어의 길이
- c. 단어가 나타나는 문서 수
- d. 전체 문서 수
- e. 단어의 철자 수

13. 다음 중 Neural Style Transfer(NST)에 사용되는 구성 요소를 모두 고르시오.

- a. GAN 기반 생성자
- b. Content loss
- c. Style loss
- d. Gram matrix
- e. VGG16 feature extractor
- f. TfidfVectorizer

14. 다음 Gram Matrix 계산 함수에 대한 설명으로 옳은 것을 모두 고르시오.

```
def gram_matrix(ip):  
    B, C, H, W = ip.size()  
    feats = ip.view(B * C, H * W)  
    gram = torch.mm(feats, feats.t())  
    return gram / (B * C * H * W)
```

- a. Gram Matrix 는 채널 간 상관관계를 나타낸다
- b. Feature map 의 Flatten 결과를 바탕으로 계산된다
- c. 스타일 손실 계산에 사용되는 주요 행렬이다
- d. 연산 결과는 항상 정방행렬이다
- e. 이미지의 색상만 반영된다 → 공간/채널 간 연관 모두 포함한다.

15. CAM 시각화 기법이 정상적으로 작동하기 위한 모델 구조 요건은?

- a. Dropout Layer 후 Fully Connected Layer
- b. 마지막 Convolution + Global Average Pooling + FC
- c. FC Layer 만 있는 구조
- d. 입력 이미지의 크기 제한 없음
- e. BatchNorm 이 반드시 포함되어야 함

16. 다음 중 3D Rendering 에서 NeRF 의 입력 및 출력 요소로 옳은 것을 고르시오.

- a.  $(x, y, z)$  위치
- b. 시선 방향  $(\theta, \varphi)$
- c. RGB 색상
- d. 텍스처 좌표
- e. 밀도  $\sigma$

17. Gaussian Splatting 의 렌더링 품질과 효율을 조절하는 핵심 기법은?

- a. Noise Regularization
- b. Adaptive Density Control  
→ 각 Gaussian 의 밀도와 크기를 조정해 표현 품질을 유동적으로 제어
- c. Positional Encoding
- d. GAN Loss Adjustment
- e. Image Pyramid Sampling

18. DQN 의 안정성을 높이기 위한 기법으로 적절한 것은?

- a. Experience Replay → 데이터 decorrelation
- b.  $\epsilon$ -soft Policy → 탐험/이용 균형
- c. Target Network → 안정적 Q 업데이트
- d. One-hot Encoding
- e. Dynamic Threshold Scaling

19. Experience Replay 에서 사용하는 주요 기능은?

- a. 상태 전이 확률 계산
- b. Q-table 직접 업데이트
- c. 메모리 버퍼 샘플링
- d. 연관성 낮은 샘플로 학습
- e. 예측과 타겟 네트워크 일치

20. 아래 코드의 출력을 예측하시오.

```
gamma = 0.9
rewards = [1, 0, 0, 2]
G = 0
for r in reversed(rewards):
    G = r + gamma * G
print(round(G, 2))
```

- a. 2.81
- b. 3.61
- c. 2.46
- d. 1.90
- e. 4.39

$$\begin{aligned} G_3 &= 2 \\ G_2 &= 0 + 0.9 \times 2 = 1.8 \\ G_1 &= 0 + 0.9 \times 1.8 = 1.62 \\ G_0 &= 1 + 0.9 \times 1.62 = 2.458 \approx 2.46 \end{aligned}$$

21. 다음은 Q-learning 의 핵심 업데이트 식이다. 다음 조건을 만족하는 update\_q 함수를 구현하시오.

- Q 는 상태-행동 값 테이블 (numpy 2D array)
- 입력: 상태, 행동, 보상, 다음 상태, 학습률, 감가율
- 출력: Q[state, action]을 업데이트

```
def update_q(Q, state, action, reward, next_state, alpha, gamma):
    max_next_q = np.max(Q[next_state])
    Q[state, action] += alpha * (reward + gamma * max_next_q - Q[state, action])
```

#### ► Q-learning in stochastic (real) world

- TD learning

$\alpha$  = learning rate

$$Q(s, a) = r(s, a) + \gamma \max_a Q(s', a)$$

Diagram labels: state points to  $s$ , action points to  $a$ , reward points to  $r(s, a)$ , discount factor points to  $\gamma$ .

$$Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a')]$$

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$